

数理统计期末复习

- 基本概念

- 概率论: 随机变量, 分布函数, 大数定律, 中心极限定理
- 统计量:
 - 定义: $\{x_1, \dots, x_n\}$ 是样本, $T_n = f(x_1, \dots, x_n)$, 若 f 为已知函数且不依赖任何未知参数, 则 T_n 是统计量
 - 例子: 中位数, 次序统计量, 方差, 均值, ...
- 充分统计量
 - 定义: 若 $T_n = f(X_1, \dots, X_n)$ 是充分统计量, 则 $P((X_1, \dots, X_n) \leq (x_1, \dots, x_n) | T_n = t)$ 不依赖于 θ
 - 因子分解定理: 设 $X = (X_1, \dots, X_n) \sim f_\theta(x_1, \dots, x_n)$, $T(X)$ 是一个统计量. 则 $T(X)$ 是充分统计量的充分必要条件是: $f_\theta(x_1, \dots, x_n)$ 可以分解为 $f_\theta(x_1, \dots, x_n) = g_\theta(T(x_1, \dots, x_n))h(x_1, \dots, x_n)$. 其中 $h(x_1, \dots, x_n)$ 不依赖于 θ , 对于连续随机变量 $f_\theta(x_1, \dots, x_n)$ 是概率密度函数, 对于离散随机变量 $f_\theta(x_1, \dots, x_n) = P_\theta(X_1 = x_1, \dots, X_n = x_n)$.
 - 例子: 高斯分布 $(\sum_i x_i, \sum_i x_i^2)$, 均匀分布 $(\max_i x_i)$, 二项分布 $(\sum_i x_i)$
 - (离散)因子分解定理的证明
- 统计推断:
 - 点估计: $X \sim f_\theta(x)$, 通过样本 $\{X_1, \dots, X_n\}$ 来估计 θ , $\hat{\theta} = T(X_1, \dots, X_n)$ 称为 θ 的点估计
 - 假设检验
- 标准

- 无偏性: 样本方差
- (强/弱)相合性: (强/弱)大数定律

- $\bar{x} \xrightarrow{a.s.} \mu$ (证明: 大数定律)

- $\hat{\sigma}^2 \xrightarrow{a.s.} \sigma^2$ (证明: 大数定律)

- 样本中位数: $X_{(\frac{n}{2})} \xrightarrow{a.s.} m[X]$

- hint: 利用 $\frac{1}{n} \sum_{i=1}^n 1_{\{X_i \leq x\}} \xrightarrow{a.s.} P(X \leq x)$ (两点分布大数定律), 证明

$$m[X] - \epsilon \leq X_{(\frac{n}{2})} \leq m[X] + \epsilon, \forall \epsilon > 0$$

- 最大值: $X \sim U[0, \theta] \quad \max_i x_i \xrightarrow{a.s.} \theta$

- Borel-Cantelli Lemma: 若 $\sum_{i=1}^{\infty} P(|X_i - X| \geq \epsilon) < \infty, \forall \epsilon > 0$, 则 $X_n \xrightarrow{a.s.} X$

- 渐进正态性: 中心极限定理, MLE的渐近正态性, 等等

- 点估计

• 矩方法/估计

- 定义: 总体k阶矩是参数的函数, 于是参数可以用总体k阶矩表示. 总体k阶矩可以用样本估计, 于是通过方程组可以解出参数
- 例子: 估计高斯分布的均值和方差

• 极大似然估计

- 已知: $X \sim f_{\theta_0}(x) \quad (X_1, \dots, X_n) \sim f(x_1, \dots, x_n, \theta_0)$

- 定义: $\hat{\theta} = \arg \max_{\theta \in \Theta} f(x_1, \dots, x_n, \theta) = \arg \max_{\theta \in \Theta} \sum_{i=1}^n \log f_{\theta}(x_i)$

- 相合性: $\hat{\theta} \xrightarrow{a.s.} \theta_0$

- 由大数定律可得: $\frac{1}{n} \sum_{i=1}^n \log f_{\theta}(x_i) \xrightarrow{a.s.} \mathbb{E}[\log f_{\theta}(x)]$
- 可以证明: $\frac{\partial}{\partial \theta} \mathbb{E}[\log f_{\theta}(x)] \Big|_{\theta=\theta_0} = 0$ 且 $\frac{\partial^2}{\partial \theta^2} \mathbb{E}[\log f_{\theta}(x)] \Big|_{\theta=\theta_0} < 0$
- 有/无偏: MLE可能是无偏估计(二项分布), 也可能是有偏估计(高斯分布的方差, 均匀分布的最大值)
- 例子: 二项分布, 均匀分布($X \sim U[0, \theta]$, $\hat{\theta} = X_{(n)}$), 高斯分布
- 渐近正态性: $\sqrt{n}(\hat{\theta} - \theta_0) \xrightarrow{d} \mathcal{N}(0, \frac{1}{I(\theta_0)})$
- *高斯发现正态分布的过程
- 一致最小方差无偏估计(UMVUE)
 - 定义: 若 $E_{\theta}[\hat{g}(X)] = E_{\theta}[g(\theta)] \quad \forall \theta \in \Theta$, 则称 $\hat{g}(X)$ 是 $g(\theta)$ 的无偏估计; $\hat{g}(X)$ 是无偏估计, 且对任一无偏估计 $\hat{g}_1(X)$ 都有 $Var_{\theta}(\hat{g}(X)) \leq Var_{\theta}(\hat{g}_1(X)) \quad \forall \theta \in \Theta$, 则称 $\hat{g}(X)$ 是 $g(\theta)$ 的一致最小方差无偏估计
 - 引理: $\hat{g}(X)$ 是无偏估计, T 是充分统计量. 定义 $H := E[\hat{g}(X) | T] = G(T)$, 可以证明 H 是一统计量且还是 $g(\theta)$ 的无偏估计, 则有 $Var[H] \leq Var[\hat{g}(X)] \quad \forall \theta \in \Theta$.
(此引理告诉我们在有充分统计量 T 时, 为求 UMVUE, 只需考虑能表达为 T 的函数的无偏估计类)
 - 引理的证明 hint: $\mathbb{E}[X]^2 \leq \mathbb{E}[X^2]$, $\mathbb{E}[\hat{g}(X) | T_n] - g(\theta) = \mathbb{E}[\hat{g}(X) - g(\theta) | T_n]$,
 $\mathbb{E}[\mathbb{E}[X | Y]] = \mathbb{E}[X]$
- 零无偏估计法: 验证某个特定的估计量 $\hat{g}(X)$ 为 UMVUE 的工具
 - 定理: 设 $\hat{g}(X)$ 是 $g(\theta)$ 的一个无偏估计, $Var[\hat{g}(X)] < \infty \quad (\forall \theta \in \Theta)$, 且对任何满足条件 “ $\mathbb{E}[l(X)] = 0 \quad (\forall \theta \in \Theta)$ ” 的统计量 $l(X)$ 都有 $Cov[\hat{g}(X), l(X)] = 0 \quad (\forall \theta \in \Theta)$, 则称 $\hat{g}(X)$ 是 $g(\theta)$ 的 UMVUE. 并且可以说明 $\hat{g}(X)$ 是 $g(\theta)$ 唯一的 UMVUE.

- 定理的证明hint: $Cov[\hat{g}(X), l(X)] = E[\hat{g}(X) \cdot l(X)]$, $l(X) := \hat{g}_1(X) - \hat{g}(X)$
- (补充)推论: 假设 $T_n = T(X_1, \dots, X_n)$ 是充分统计量, 设 $\hat{g}(T_n)$ 是 $g(\theta)$ 的一个无偏估计, $Var[\hat{g}(T_n)] < \infty$ ($\forall \theta \in \Theta$), 且对任何满足条件“ $E[l(T_n)] = 0$ ($\forall \theta \in \Theta$)”的统计量 $l(T_n)$ 都有 $Cov[\hat{g}(T_n), l(T_n)] = 0$ ($\forall \theta \in \Theta$), 则称 $\hat{g}(T_n)$ 是 $g(\theta)$ 的UMVUE.

- 证明hint: 结合上述的引理和定理

- 例子:

- 二项分布($X \sim B(p)$): $E[l(T_n)] = 0 \Rightarrow l(T_n)$

- 均匀分布($X \sim U[0, \theta]$): $\hat{\theta} := \frac{n+1}{n} \max_{1 \leq i \leq n} X_i$, $E[l(T_n)] = 0 \Rightarrow l(T_n)$

- 完备统计量

- 定义: 假设 T 是一个统计量, 若对任意不依赖于 θ 的函数 $L(\cdot)$ 满足 $E[L(T)] = 0, \forall \theta \in \Theta \Rightarrow L(T) = 0$, 则称 T 是完备统计量

- 定理: 假设 T 是充分且完备的统计量, 且 $\hat{g}(T)$ 是 $g(\theta)$ 的无偏估计, 且 $Var[\hat{g}(T)] < \infty$, 则 $\hat{g}(T)$ 是 $g(\theta)$ 的唯一的UMVUE

• 证明: 构造 $L(T) = \hat{g}(T) - \hat{g}_1(T)$

- 定理: 设样本 X 有概率密度函数 $f_\theta(x) = c(\theta) \exp\{\sum_{i=1}^k T_i(x) Q_i(\theta)\} h(x)$, 则统计量

$T = (T_1(X), \dots, T_k(X))$ 是充分的. 若进一步地,

$\{(Q_1(\theta), \dots, Q_k(\theta)) : \theta \in \Theta\}$ 有内点, 则 T 是完备的

• 例子: 可以证明 $T = (\sum_{i=1}^n x_i, \sum_{i=1}^n x_i^2)$ 是充分完备统计量, $(\bar{x}, \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2)$

是 $X \sim \mathcal{N}(\mu, \sigma^2)$ 唯一的UMVUE

- C-R不等式

- 若 $\hat{g}(X)$ 是 $g(\theta)$ 的无偏估计, 那么有 $\text{Var}[g(\hat{X})] \geq \frac{\left(\frac{\partial g(\theta)}{\partial \theta}\right)^2}{I(\theta)}$
- 证明 hint: $\int (\hat{g}(x) - g(\theta)) \frac{\partial f_\theta(x)}{\partial \theta} dx = \frac{\partial g(\theta)}{\partial \theta}$,
 $\int f \cdot g dx \leq \left(\int f^2 dx\right)^{\frac{1}{2}} \left(\int g^2 dx\right)^{\frac{1}{2}}$ (Cauchy-Schwarz Inequality)
- 意义: 给出了无偏估计的方差的下界, 定义了Fisher信息量
 $I(\theta) = \mathbb{E}\left[\frac{\partial \log f_\theta(x)}{\partial \theta}\right]^2$, 注意 $f_\theta(x)$ 为样本的联合分布概率密度函数
- 例子:
 - n 个 IID 随机变量, $I(\theta) = nI^*(\theta)$, $I^*(\theta)$ 为单个样本的Fisher信息量
 - 高斯分布 ($X \sim \mathcal{N}(\mu, \sigma_0^2)$): 可以证明 $\text{Var}[\bar{x}]$ 达到了C-R不等式给出的下界
 - 极大似然估计的渐近正态性 $\sqrt{n}(\hat{\theta} - \theta) \rightarrow \mathcal{N}(0, \frac{1}{I^*(\theta)})$

- 假设检验

- 错误类型:
 - 第一类: H_0 正确, 但被拒绝
 - 第二类: H_0 错误, 但被接受
- Neyman-Pearson 准则: 控制第一类错误的概率 ($\leq \alpha$), 最小化第二类错误的概率
- 单样本 t 检验
 - 假设: $X \sim \mathcal{N}(\mu, \sigma^2)$, $H_0: \mu = 0$

构造 t 统计量: $T_n := \frac{\sqrt{n}\bar{x}}{\hat{S}_n} \xrightarrow{d} \mathcal{N}(0,1)$ where $\hat{S}_n^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$

- t随机变量: $X \sim \mathcal{N}(0,1), Y \sim \chi^2(n), t(n) := \frac{X}{\sqrt{\frac{Y}{n}}}$

- 可以证明在 H_0 成立时: $T_n \sim t(n-1)$

• 重要结论: 假设 $X \sim \mathcal{N}(\mu, \sigma^2)$, 则 $\sum_{i=1}^n (X_i - \bar{X})^2 \sim \chi^2(n-1)$ 且 \bar{X} 与

$\sum_{i=1}^n (X_i - \bar{X})^2$ 独立

• 两样本t检验:

- 假设: $X \sim \mathcal{N}(\mu_1, \sigma^2), Y \sim \mathcal{N}(\mu_2, \sigma^2), H_0: \mu_1 \neq \mu_2$

- 构造两样本t统计量:

$$T_n := \frac{\sqrt{\frac{n_1 n_2}{n_1 + n_2}} (\bar{X} - \bar{Y})}{\hat{S}_n}, \hat{S}_n^2 = \frac{1}{n_1 + n_2 - 2} \left\{ \sum_{i=1}^{n_1} (x_i - \bar{x})^2 + \sum_{i=1}^{n_2} (y_i - \bar{y})^2 \right\}$$

- 可以证明在 H_0 成立时: $T_n \sim t(n_1 + n_2 - 2)$

• χ^2 分布的性质: $X \sim \chi^2(n), Y \sim \chi^2(m), X \perp Y \Rightarrow X + Y \sim \chi^2(m+n)$

• $\frac{1}{\sigma} \sqrt{\frac{n_1 n_2}{n_1 + n_2}} (\bar{X} - \bar{Y}) \sim \mathcal{N}(0,1), \frac{1}{\sigma} \hat{S}_n^2 \sim \chi^2(n_1 + n_2 - 2)$

• 相关性检验

- 假设: $X, Y \quad H_0: \rho(X, Y) = 0$

- 样本协方差: $\hat{\rho}_n = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}, \hat{\rho}_n \xrightarrow{a.s.} \rho$

- 在 H_0 成立时: $\sqrt{n} \hat{\rho}_n \xrightarrow{d} \mathcal{N}(0,1)$

- χ^2 检验: is any statistical hypothesis test where the sampling distribution of the test statistic is a chi-squared distribution when the null hypothesis is true.

- Pearson's χ^2 test for Multinomial data

- 不含未知参数

- 假设: $H_0 : P_j = P_{0j} \ (0 \leq j \leq r) \quad \{P_{0j}\}_{j=0}^r$ 已知

- 构造: $T_n = \sum_{j=0}^r \frac{(n_j - nP_{0j})^2}{nP_{0j}}$ where $n_j = \sum_{i=1}^n 1_{\{x_i=j\}}$

- 定理: 在 H_0 成立时: $T_n \xrightarrow{d} \chi^2(r)$

- 含未知参数

- 假设: $H_0 : P_j = P_{0j}(\theta_1, \dots, \theta_d)$

- 构造: $T_n = \sum_{j=0}^r \frac{(n_j - nP_{0j}(\hat{\theta}_1, \dots, \hat{\theta}_d))^2}{nP_{0j}(\hat{\theta}_1, \dots, \hat{\theta}_d)}$ where

$$(\hat{\theta}_1, \dots, \hat{\theta}_d) = \arg \max_{\theta_1, \dots, \theta_d} \prod_{i=1}^n (P_{0j}(\theta_1, \dots, \theta_d))^{x_i} = \arg \max_{\theta_1, \dots, \theta_d} \prod_{j=0}^r (P_{0j}(\theta_1, \dots, \theta_d))^{n_j}$$

- 在 H_0 成立时: $T_n \xrightarrow{d} \chi^2(r - d)$

- 例子(χ^2 独立性检验):

- $H_0 : P(A = i, B = j) = P(A = i)P(B = j)$

$$T_n = \sum_{i=0}^r \sum_{j=0}^s \frac{(n_{ij} - n\hat{P}(A=i)\hat{P}(B=j))^2}{n\hat{P}(A=i)\hat{P}(B=j)}$$

$$\hat{P}(A=i) = \frac{\sum_j n_{ij}}{n}, \quad \hat{P}(B=j) = \frac{\sum_i n_{ij}}{n}$$

- 在 H_0 成立时: $T_n \xrightarrow{d} \chi^2((r+1)(s+1) - 1 - (r+s)) = \chi^2(rs)$

- 连续随机变量

- 假设: $X \sim f(x)$ $H_0: f(x) = f_0(x)$, $f_0(x)$ 已知

- 另一种方法: 经验分布函数 $\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n 1_{\{x_i \leq x\}}$

- 非参数检验

- 置换检验(两样本问题)

- 假设: $X \sim F_X, Y \sim F_Y$ $H_0: F_X = F_Y$

- 样本: $\{X_1, \dots, X_n, Y_1, \dots, Y_m\}$

- 构造: $T = \bar{X}_n - \bar{Y}_m$

- $P(|T| \geq c | H_0) = \frac{\sum_{i=1}^N 1_{\{|H_i| \geq c\}}}{N}$ where $N = C_{n+m}^n$

- 当n和m较大时, 置换检验不再适用

- 秩和检验(两样本问题)

- 假设: $X \sim F_X, Y \sim F_Y$ $H_0: F_X = F_Y$

- 样本: $\{X_1, \dots, X_{n_1}, Y_1, \dots, Y_{n_2}\}$

- 统计量: 排序后获得 $\{X_1, \dots, X_{n_1}\}$ 的序 $\{R_1, \dots, R_{n_1}\}$, 构造 $T = \sum_{i=1}^{n_1} R_i$

- 根据大样本理论, 在 H_0 成立时: $\frac{T - \frac{1}{2}n_1(n_1 + n_2 + 1)}{\sqrt{\frac{1}{12}n_1n_2(n_1 + n_2 + 1)}} \xrightarrow{d} \mathcal{N}(0, 1)$

$$\mathbb{E}[T] = \sum_{i=1}^{n_1} \mathbb{E}[R_i] = \sum_{i=1}^{n_1} \sum_{k=1}^{n_1+n_2} k \cdot P(R_i = k)$$

$$\text{Var}[T] = \sum_{i=1}^{n_1} \text{Var}[R_i] + \sum_{i \neq j} \text{Cov}[R_i, R_j]$$

$$\text{Var}[R_i] = \mathbb{E}[R_i^2] - \mathbb{E}^2[R_i] = \frac{1}{12}(N^2 - 1),$$

$$\text{Cov}[R_i, R_j] = -\frac{N+1}{12} \quad (i \neq j)$$

- 证明参考: <https://stats.stackexchange.com/a/316208/169345>

• 似然比检验

- 假设: $X \sim f_\theta(x), \theta \in \Theta \quad H_0 : \theta \in \Theta_0$

$$\text{统计量: } T_n = \frac{\max_{\theta \in \Theta} \prod_{i=1}^n f_\theta(x_i)}{\max_{\theta \in \Theta_0} \prod_{i=1}^n f_\theta(x_i)}$$

- 例1: $X \sim \mathcal{N}(\mu, \sigma^2) \quad H_0 : \mu = 0$

- 例2: $X \sim \mathcal{N}(\mu, \sigma^2) \quad H_0 : \sigma^2 = \sigma_0^2$

- (补充) Wilks's Theorem: If $\dim(\Theta) - \dim(\Theta_0) = t > 0$ and H_0 holds, then

$$\lim_{n \rightarrow \infty} 2 \ln T_n \sim \chi^2(t)$$

• 多重检验: 同时进行多个假设检验时,需要修改拒绝域

$$\text{FWER(组间误差): } P(\cup_{i \in H_0} \{|T_i| \geq t\}) \leq \sum_{i \in H_0} P(|H_i| \geq t) \leq m \cdot P(|H_i| \geq t)$$

表示第一类错误至少出现一次(rejecting at least one true null hypothesis)的概率

- Bonferroni Method(控制FWER $\leq \alpha$): $P(|H_i| \geq t) \leq \frac{\alpha}{m}$ 缺点:过于保守,几乎不会拒绝原假设

$$\text{FDP(错误发现比例): } FDP = \frac{\sum_{i \in H_0} 1_{\{|T_i| \geq t\}}}{\max\{\sum_{i=1}^m 1_{\{|T_i| \geq t\}}, 1\}}$$

$$\text{FDR(错误发现率): } FDR = \mathbb{E} \left[FDP = \frac{\sum_{i \in H_0} 1_{\{|T_i| \geq t\}}}{\max \{ \sum_{i=1}^m 1_{\{|T_i| \geq t\}}, 1 \}} \right]$$

- p-value

- 定义: $p := 1 - F(|T|)$ 其中 $F(\cdot)$ 是在原假设成立情况下的cdf (注: 该定义并非一般性定义)

$$\hat{t} = \sup \left\{ 0 < t < 1 : \frac{mt}{\max \{ \sum_{i=1}^m 1_{\{p_i \leq t\}}, 1 \}} \leq \alpha \right\}, \text{ 若 } p_i \leq \hat{t}, \text{ 则拒绝 } H_{0i}$$

$$\text{对比: } \hat{t} = \inf \left\{ t > 0 : \frac{mP(|\mathcal{N}(0,1)| \geq t)}{\max \{ \sum_{i=1}^m 1_{\{p_i \leq t\}}, 1 \}} \leq \alpha \right\}, \text{ 若 } |T_i| \geq \hat{t}, \text{ 则拒绝 } H_{0i}$$

- B-H method(控制 $FDR \leq \alpha$)

- $p_{(1)} < p_{(2)} < \dots < p_{(m)}$

- $\hat{k} = \max \{ k : p_{(k)} \leq \frac{\alpha k}{m} \}$

- 若 $p_i \leq p_{(\hat{k})}$, 则拒绝 H_{0i}

- (补充定理) 不论原假设为真的数量 m_0 有多少, 不管原假设为假的p值的分布如何, B-H方法总可以控制 $FDR \leq \frac{m_0}{m} \alpha \leq \alpha$.

- 多元分析

- 多元正态分布

$$\text{定义1: 若 } f(x) = \frac{1}{(2\pi)^{n/2} |\Sigma|^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu) \right\} \text{ 则称}$$

$$X \sim \mathcal{N}(\mu, \Sigma)$$

- 定义2: 若对 $\forall t \in \mathbb{R}^m$ 有 $t^T x \sim \mathcal{N}(t^T \mu, t^T \Sigma t)$, 则称 $X \sim \mathcal{N}(\mu, \Sigma)$
- 可以证明: 定义1 \iff 定义2

- 证明定义2 \Rightarrow 定义1的步骤如下:

- 若 $X \sim \mathcal{N}(\mu, \Sigma)$, 则 $AX \sim \mathcal{N}(A\mu, A\Sigma A^T)$, 更一般地,
 $AX + b \sim \mathcal{N}(A\mu + b, A\Sigma A^T)$
- 若 $X_i, X_j \sim \mathcal{N}$ 且 $\text{cov}(X_i, X_j) = 0$, 则 X_i 与 X_j 独立. 更一般地, 对于MVN, 两组变量不相关 \Leftrightarrow 两组变量独立 (证明: 随机变量的特征函数 $f(t) = \mathbb{E}[e^{it^T x}]$,
$$\mathbb{E}[e^{it^T X}] = \mathbb{E}[e^{it_{S_1}^T X_{S_1}}] \mathbb{E}[e^{it_{S_2}^T X_{S_2}}] \iff X_{S_1} \perp X_{S_2}$$
)
- 由上面两个结论可得, 若 $X \sim \mathcal{N}(\mu, \Sigma)$, 则 $\Sigma^{-\frac{1}{2}}(X - \mu) \sim \mathcal{N}(0, I)$
- 概率变换公式: 已知 $X \sim f_X(x)$, $Y = g(X)$, 则
$$f_Y(y) = f_X(g^{-1}(y)) \left| \frac{\partial(x_1, \dots, x_n)}{\partial(y_1, \dots, y_n)} \right|$$

- 数据的分类:

- 问题: $X \sim f_1, Y \sim f_2$, 找到 \mathfrak{R}^p 的一个划分 $R_1 \cup R_2 = \mathfrak{R}^p, R_1 \cap R_2 = \emptyset$, 当 $Z \in R_1$ 时认为 $Z \in X$, 当 $Z \in R_2$ 时认为 $Z \in Y$.
- 错误分类概率:
$$\Delta = P(Z \in R_2 | Z \sim f_1) + P(Z \in R_1 | Z \sim f_2) = \int_{R_2} f_1(x) dx + \int_{R_1} f_2(x) dx$$

$$= 1 - \int_{R_1} (f_1(x) - f_2(x)) dx$$
- 目标: $\min_{R_1} \Delta \iff \max_{R_1} \int_{R_1} (f_1(x) - f_2(x)) dx$
- 最优解: $R_1 = \{x | f_1(x) \geq f_2(x)\}$
- Fisher线性判别式(LDA)
 - 假设: $X \sim \mathcal{N}(\mu_1, \Sigma), Y \sim \mathcal{N}(\mu_2, \Sigma) \in \mathfrak{R}^p$

- $\{x : \frac{f_1(x)}{f_2(x)} \geq 1\} = \{x : (x - \frac{\mu_1 + \mu_2}{2})^T \Sigma^{-1}(\mu_1 - \mu_2)\}$
- 判别向量: $\beta := \Sigma^{-1}(\mu_1 - \mu_2)$ 可解线性方程组 $\Sigma\beta = (\mu_1 - \mu_2)$ 得到
- $\hat{\mu}_1 = \bar{X}, \hat{\mu}_2 = \bar{Y}, \hat{\Sigma} = \frac{1}{n_1 + n_2 - 2} \left\{ \sum_{i=1}^{n_1} (X_i - \bar{X})(X_i - \bar{X})^T + \sum_{i=1}^{n_2} (Y_i - \bar{Y})(Y_i - \bar{Y})^T \right\}$
- 二次判别式(QDA)
 - 假设: $X \sim \mathcal{N}(\mu_1, \Sigma_1), Y \sim \mathcal{N}(\mu_2, \Sigma_2) \in \mathfrak{R}^p$
 - $\hat{\Sigma}_1 = \frac{1}{n_1 - 1} \sum_{i=1}^{n_1} (X_i - \bar{X})(X_i - \bar{X})^T, \hat{\Sigma}_2 = \frac{1}{n_2 - 1} \sum_{i=1}^{n_2} (Y_i - \bar{Y})(Y_i - \bar{Y})^T$
- 最优预测 (补充: 也叫最小均方误差预测)
 - 定义: $\hat{f} = \arg \min_f \mathbb{E}[(Y - f(X))^2]$
 - 可以证明, 最优预测为 $\hat{f}(X) = \mathbb{E}[Y | X]$ (hint: $\mathbb{E}[Y - f(X)]^2 = \mathbb{E}[Y - \mathbb{E}[Y | X] + \mathbb{E}[Y | X] - f(X)]^2$, $\mathbb{E}[AB] = \mathbb{E}[\mathbb{E}[AB | X]]$)
 - 例子: 假设 $X \sim \mathcal{N}(\mu = 0, \Sigma)$, 可以证明存在 $\{\beta_i\}_{i=2}^p$ 使得

$$X_1 = \sum_{i=2}^p \beta_i X_i + \epsilon_1, \quad \mathbb{E}[\epsilon_1] = 0, \quad \epsilon_1 \perp X_i \quad (2 \leq i \leq p).$$
 在这种情况下有

$$\mathbb{E}[X_1 | X_2, \dots, X_p] = \sum_{i=2}^p \beta_i X_i$$

 - 证明 hint: $\beta_i = -\frac{w_{1i}}{w_{11}}$ or $\beta_i = w_{1i}, \mathbb{E}[X_i \epsilon_1] = 0 \iff X_i \perp \epsilon_1 \quad (2 \leq i \leq p)$

- 线性回归
 - 模型: $Y = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p + \epsilon$ or $Y = X\beta + \epsilon$ where $\epsilon \perp X_1, \dots, X_p, \mathbb{E}[\epsilon] = 0$ and $X = \begin{bmatrix} 1 & X_1 & \dots & X_p \end{bmatrix}$

- Y: 响应变量, X: 协变量, β : 回归系数

- 目标: 估计参数 β_0, \dots, β_p

- β 的最小二乘估计: $\hat{\beta} = (X^T X)^{-1} X^T Y$

- 假设 $\epsilon \sim \mathcal{N}(0, \sigma^2)$:

• 则 $\hat{\beta} - \beta = (X^T X)^{-1} X^T \epsilon \sim \mathcal{N}(0, \sigma^2 (X^T X)^{-1})$

• 定义: 残差: $\hat{\epsilon} = \begin{bmatrix} Y_1 - X_1 \hat{\beta} \\ \vdots \\ Y_n - X_n \hat{\beta} \end{bmatrix}$, $\hat{\sigma}^2 = \frac{1}{n-p-1} \sum_{i=1}^n \hat{\epsilon}_i^2 = \|\hat{\epsilon}\|^2$

• 可以证明:

$$\hat{\sigma}^2 \sim \frac{\sigma^2}{n-p-1} \chi^2(n-p-1)$$

• 证明hint: $\hat{\epsilon} = H\epsilon$ where $H := I_n - X(X^T X)^{-1} X^T$ is idempotent; SVD: $H = UDU^T$; singular values of idempotent matrix is 0 or 1; sum of eigenvalues of a square matrix A $\sum_i \lambda_i = \text{tr}(A)$; $\text{tr}(AB) = \text{tr}(BA)$

- $\hat{\sigma}$ 与 $\hat{\beta}$ 独立 ($\text{cov}[\hat{\epsilon}, \hat{\beta}] = \mathbb{E}[\hat{\epsilon} \hat{\beta}^T] - \mathbb{E}[\hat{\epsilon}] \mathbb{E}[\hat{\beta}]^T = 0$)

- 假设检验: $\hat{\beta}_i \sim \mathcal{N}(\beta_i, \sigma^2 w_{ii})$, $H_0 : \beta_i = 0$ $H_1 : \beta_i \neq 0$

• 统计量: $T_i = \frac{|\hat{\beta}_i|}{\hat{\sigma} \sqrt{w_{ii}}}$

• 可以证明在 H_0 成立时: $T_i \sim |t(n-p-1)|$

• 多重假设检验(FWER/FDR): $H_{0i} : \beta_i = 0$ ($1 \leq i \leq p$)

• 似然比检验:

- 假设: $H_0 : \beta_s = 0, s \in \{1, 2, \dots, p\}$

$$\text{统计量: } T_n = \frac{\max_{\beta \in \mathfrak{R}^{p+1}} L(\beta | X, Y)}{\max_{\beta_s=0} L(\beta | X, Y)}$$

- 条件相关性

- $\text{cov}[X_1, X_2 | X_3] = \mathbb{E}[X_1 X_2 | X_3] - \mathbb{E}[X_1 | X_3] \mathbb{E}[X_2 | X_3]$
- 设 $X \sim \mathcal{N}(\mu, \Sigma)$, $\Sigma^{-1} = [w_{ij}] \in \mathfrak{R}^{p \times p}$, 则 $\text{cov}[X_i, X_j | X_{k \neq i, j}] = 0 \iff w_{ij} = 0$

- 逻辑回归

$$\text{模型: } P(Y = 1 | X_1, \dots, X_p) = \frac{1}{1 + \exp\{\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p\}}$$

- 概率解释: 混合高斯分布

- 分位数回归

- 问题: 给定 α , 求 y , 使得 $P(Y \leq y | X) = \alpha$
- 模型(线性假设): $y = \beta_0(\alpha) + \beta(\alpha)^T X$
- 损失函数: $\rho_\alpha(x) := (\alpha - 1_{\{x < 0\}}) \cdot x$

$$\text{优化目标: } \hat{\beta}_0, \hat{\beta} = \arg \min_{\beta_0, \beta} \frac{1}{n} \sum_{i=1}^n \rho_\alpha(y_i - \beta_0 - \beta^T x_i)$$

$$\sqrt{n}[(\hat{\beta}_0, \hat{\beta}) - (\beta_0, \beta)] \xrightarrow{d} \mathcal{N}(0, A)$$

$$\text{中位数回归: } \alpha = \frac{1}{2}, \text{ 绝对值损失}$$

- 支持向量机: $\min_{\beta_0, \beta} \mathbb{E} (1 - Y(\beta_0 + \beta^T X))_+$ and

$$(\hat{\beta}_0, \hat{\beta}) = \arg \min_{\beta_0, \beta} \frac{1}{n} \sum_{i=1}^n (1 - Y(\beta_0 + \beta^T X))_+$$

- 主成分分析

- 主成分等于 Σ 的特征向量, 方差等于 Σ 的特征值

$$\frac{\text{Var}(Y_1)}{\sum_i \text{Var}(Y_i)} = \frac{\lambda_1}{\sum_i \lambda_i}$$

- 稀疏主成分分析: 当 p 很大时, Σ 是奇异的, 不能作出很好的估计. 实际上并不是每个位置都要估计, 对于 $u = (u_1 \cdots u_p)^T$, 大部分 $u_i = 0$.

$$\max_v v^T \Sigma v \quad s.t. \quad \|v\|_2 = 1, \|v\|_0 \leq k$$

- 优化问题:

$$\text{目标: } \hat{\theta} = \arg \min_{\theta \in \mathbb{R}^p} \frac{1}{n} \sum_{i=1}^n f(x_i, \theta), f(\cdot) \text{ 是已知的凸的损失函数}$$

- 估计方法1:

$$\bullet \quad \theta_{t+1} = \theta_t - A^{-1} \frac{1}{n} \sum_i \frac{\partial}{\partial \theta} f(x_i, \theta) \text{ where } A = \frac{1}{n} \sum_i \frac{\partial^2}{\partial \theta^2} f(x_i, \theta)$$

$$\bullet \quad \text{复杂度: } O(n(p^2 + p) + p^3)$$

- 估计方法2(随机梯度下降):

$$\bullet \quad \theta_{t+1} = \theta_t - n_t \frac{\partial}{\partial \theta} f(x_{I_t}, \theta) \text{ where } I_t \sim U(\{1, 2, \dots, n\}), n_t \text{ 是步长}$$

$$\bullet \quad \text{复杂度: } O(p)$$

$$\bullet \quad \text{可证明: 当 } n_t \text{ 合理时, } |\theta_n - \hat{\theta}| = O\left(\frac{1}{\sqrt{n}}\right)$$

$$\bullet \quad \text{贝叶斯统计: } f(\theta | X) = \frac{f(X | \theta) f(\theta)}{\sum_{\theta_i \in \Theta} f(X | \theta_i) f(\theta_i)}$$